李天昊

tianhao.li | tianhao.li@duke.edu | 领英 | 谷歌学术 | Orcid | Github

教育背景

杜克大学 **2024年8月 - 2026年5月 (预计)**

理学硕士研究生 - 医学物理

研究方向: 医疗基座模型与智能体系统的安全与隐私

导师/委员会成员: Prof. Fang-Fang Yin (DKU), Prof. Zhenyu Yang (DKU), and Prof. Neil Gong (Duke)

北方工业大学 **2020年9月 - 2024年6月**

工学学士 - 信息安全 绩点: *3.89/4* 成绩: *90.88/100* 成绩单

核心课程: 应用密码学, 数据安全, 数字图像处理, 计算机组成原理, 操作系统, 逆向工程, 数字取证, 软件安全, 网络攻防

荣誉奖项: 优秀毕业论文 (排名1/101, Top 0.99%), 一等优秀学生奖学金 (排名1/329, Top 0.30%)

学术界研究经历

威斯康星大学麦迪逊分校 **2024年10月 – 至今**

研究实习 @ 安全基础模型系统实验室（*SaFoLab*） 美国，威斯康星

- **职责**: 带领科研团队推进AgentFuzzer项目，提出统一的智能体模式描述符AgentSchemaDescriptor，基于此提出首个针对大模型智能体的系统性模糊测试框架，解决了对于智能体安全对齐测试泛化性难以提升的挑战。
- **导师**: Chaowei Xiao教授

浙江大学 **2024年8月 – 2024年10月**

访问研究员 @ 知识引擎实验室 中国，浙江

- **职责**: 带领15人科研团队推进SciSafeEval项目，提出首个面向大模型科学任务安全性的基准评测，在该基准评测下的实验结果指出：包括GPT-4o/o1-preview、LLaMa3.2、QWen2.5等在内的SOTA大语言模型(LLMs)存在生物、化学、医学、物理等科学领域的技术滥用安全风险，同时给出了基于思维链(CoT)技术与小样本学习(Few-shot)技术的有效风险缓解措施。
- **产出**: arXiv:2410.03769 | Huggingface:Tianhao0x01/SciSafeEval | Github:DavidLee528/SciSafeEval
- **导师**: 张强教授，陈华钧教授

高精尖创新研究院 **2022年7月 – 2023年7月**

研究助理 @ 虚拟与增强现实技术创新中心 中国，北京

- **职责**: 带领了一个8人研发团队，开发了基于步态的情报、监视和侦察（ISR）系统。实现了步态识别SaaS原型系统，并提出了包括身份认证、跟踪和近源渗透预警在内的安全特性。负责技术架构设计、技术报告撰写以及研究论文的撰写工作。
- **产出**: 成功申请10万人民币研发经费，发表7篇SCI/EI论文，赢得4项国家级专业比赛，3次口头报告与1篇海报汇报。
- **导师**: 王立军院士

工业界研究经历

天融信 (已发正式聘用offer) **2024年3月 – 2024年9月**

安全研究员（实习） @ 创新技术研究部 中国，北京

- **职责**: **(i)** 支撑机器学习模型安全评估项目原型系统落地，涉及到对于对抗攻击、投毒攻击、等算法的调试以及原型系统后端评估模块的开发; **(ii)** 支撑网络钓鱼电子邮件检测项目，监督数据集的收集和改进工作。成功应用大型语言模型 (LLM) 和监督微调 (SFT) 开发出强大的检测系统。
- **领导**: 创新研究总经理王玮博士

绿盟科技 **2023年9月 – 2024年3月**

安全研究员（实习） @ 创新研究院天枢实验室 中国，北京

- **职责**: **(i)** 设计绿盟大模型安全评估系统(NSFOCUS LSAS)核心算法与原型系统; **(ii)** 通过进攻性测试，即“红队”测试，提高绿盟风云卫大模型(NSFGPT)和其他私有LLM的安全和隐私性能; **(iii)** 进行文献综述，包括可信人工智能的研究论文和Gartner咨询报告，丰富威胁情报数据库; **(iv)** 撰写LLM安全技术白皮书。
- **影响**: 发布了绿盟大模型安全评估系统(LSAS)，绿盟风云卫大模型NSFGPT以及安全行业大模型SecLLM技术白皮书
- **领导**: 主管安全研究员王星凯博士, 首席创新官&创新研究总经理刘文懋博士

学术文章发表 (*通讯作者, ^{1st}共同第一作者)

生成式智能体系统安全评测与对齐

- Xiong, Q., Huang, Y., Jiang, Z., Chang, Z., Zheng, Y., **Li, T.**, & Li, M. (2025). Butterfly Effects in Toolchains: A Comprehensive Analysis of Failed Parameter Filling in LLM Tool-Agent Systems. arXiv preprint arXiv:2507.15296.

生成式基座模型安全评测与对齐

- **Li, T.**, Lu, J., Chu, C., Zeng, T., Zheng, Y., Li, M., Huang, H., Wu, B., Liu, Z., Ma, K., Yuan, X., Wang, X., Ding, K., Chen, H., & Zhang, Q.*. (2024). SciSafeEval: a comprehensive benchmark for safety alignment of large language models in scientific tasks. arXiv preprint arXiv:2410.03769. *(AAAI 2025 AICS Oral)*
- Zheng, Y.^{1st}, **Li, T.**^{1st}, Huang, H., Zeng, T., Lu, J., Chu, C., ... & Li, M. (2025). Are All Prompt Components Value-Neutral? Understanding the Heterogeneous Adversarial Robustness of Dissected Prompt in Large Language Models. arXiv preprint arXiv:2508.01554. *(AAAI 2026, submitted)*
- **Li, T.**, Zeng, T., Zheng, Y., Zhang, C., Lu, J., Huang, H., Chu, C., Yin, F.F. & Yang, Z. (2025). Synthetic Poisoning Attacks: The Impact of Poisoned MRI Image on U-Net Brain Tumor Segmentation. arXiv preprint arXiv:2502.03825. *(ICLR 2025 SynthData, AAPM 2025 Oral)*
- Zhang, Q., Ding, K., Li, M., **Li, T.**, Liu, D., & Chen, H. (2025). Comprehensive Alignment for BioMolecular Large Language Models. *Nature Computational Science (JCR-Q1, Peer Review)*
- Ghosh, S., ..., **Li, T.**, ..., Mattson, P., Liang, P., Vanschoren, J.. (2025). AILuminate: Introducing v1.0 of the AI Risk and Reliability Benchmark from MLCommons. arXiv preprint arXiv:2503.05731. (101 authors)

基于学习的模式识别与信号理解

- **Li, T**., Ma, W., Zheng, Y., Fan, X., Yang, G., Li, Y., Wang, L., & Li, Z.*. (2024). A Survey on Gait Recognition Against Occlusion: Taxonomy, Dataset and Methodology. *PeerJ Computer Science (**JCR-Q1**)*
- Wei, Y., Liu, X., Xu, C., Zhang, G., **Li, T.**, Yuan, W., Ho, H. P., & Xu, M. (2025). From Droplets to Diagnosis: AI-Driven Imaging and System Integration in Digital Nucleic Acid Amplification Testing. *Biosensors and Bioelectronics (**JCR-Q1**, Accepted)*
- Ma, W., Li, Y.*, **Li, T.**, Yang, H., Li, Z., Wang, L., & Xuan, J.. (2024). SFSWTS: EEG Emotion Recognition Based on Spatial-frequency Shifted Windows Time Self-attention Neural Network. *Neurocomputing (**JCR-Q1**)* [PDF]
- Ma, W., Zheng, Y., **Li, T.**, Li, Z., Li, Y., & Wang, L.*. (2024). A comprehensive review of deep learning in EEG-based emotion recognition: classifications, trends, and practical implications. *PeerJ Computer Science (**JCR-Q1**)* [PDF]
- **Li, T.**, Zheng, Y., Zhang, H., Ma, W., & Li, Y.*. (2023). Research on Real-time Early Warning Mechanism of Aviation Safety Based on Finite State Machine Underlying in QAR Stream Data. *Proceedings of the 2023 7th International Conference on Big Data and Internet of Things (BDIoT)* [PDF][Oral][Slide]

部分荣誉奖项

- (2024年08月) 第十七届全国大学生信息安全竞赛作品赛二等奖 [证书] 国家级
- (2024年07月) 星河生成式人工智能安全大赛攻击赛道第5名（共89队） 国家级
- (2024年02月) 2024美国大学生数学建模竞赛(MCM)S奖 [论文] 国家级
- (2023年11月) 第十一届全国大学生数字媒体科技作品及创意竞赛二等奖 [证书] 国家级
- (2023年11月) 第八届全国密码技术竞赛三等奖 [证书][名单][新闻] 国家级
- (2023年08月) 第十六届全国大学生信息安全竞赛作品赛三等奖 [证书][报告][幻灯片][演示][新闻] 国家级
- (2023年06月) 第十六届全国大学生信息安全竞赛实践赛(AWDP)三等奖 [证书] 区域级
- (2023年04月) 第十三届MathorCup数学建模挑战赛一等奖 [证书][论文] 国家级
- (2023年04月) 第十四届蓝桥杯全国软件和信息技术专业人才大赛一等奖 [证书] 省部级
- (2022年06月) 第十六届全国大学生信息安全竞赛作品赛优胜奖 [证书][报告][幻灯片] 国家级
- (2022年06月) 第十五届全国大学生信息安全竞赛实践赛(CTF)三等奖 [证书] 区域级
- (2021年06月) 第十二届蓝桥杯全国软件和信息技术专业人才大赛三等奖 [证书] 国家级
- (2021年04月) 第十二届蓝桥杯全国软件和信息技术专业人才大赛一等奖 [证书] 省部级

开源活动

- NVIDIA/garak (生成式人工智能红队工具，大模型安全领域的Metasploit，~**4.7K Stars**)

  (i) 鲁棒性提升: Python解释器版本错误修复#296; Replicate大模型生成器异常修复#401; Detector检测器基类增加异常处理逻辑的增加#566; (ii) 新特性引入: 针对LLaVA的多模态越狱攻击#587 (使其成为**世界上首个**具备多模态红队能力的工具); 多模态红队提示词探针架构升级 (#658); 全新探针SciSafeEval的引入 (#948); 生成器网络代理特性 (garak:proxy_dev). (v0.9.0.9, v0.9.0.11, v0.9.0.13)

学术演讲

- Invited talk at Institute of Software, Chinese Academy of Sciences, Toward Trustworthy Generative Foundation Models and Autonomous Agent System (25 mins), Aug 2025, Beijing, China [Link]
- Invited talk at Duke Kunshan Graduate Student Colloquium, Guardians of Trust: Safety & Privacy for Healthcare Foundation Models (15 mins), Apr 2025, Jiangsu, China [Link]
- Contributed talk at The 39th Annual AAAI Conference on Artificial Intelligence (AAAI-2025) Artificial Intelligence for Cyber Security (AICS), SciSafeEval: A Comprehensive Benchmark for Safety Alignment of Large Language Models in Scientific Tasks (20 mins), Mar 2025, Philadelphia, PA, USA [Link]

专业服务

期刊审稿人 Journal Referee

- ACM Transactions on Intelligent Systems and Technology (1);
- IEEE Transactions on Artificial Intelligence (2);
- IEEE Transactions on Biomedical Engineering (2);
- Expert Systems With Applications (1);
- Engineering Applications of Artificial Intelligence (4);
- Computer Networks (2);
- Journal of Biomedical and Health Informatics (3);
- International Journal of Human-Computer Interaction (1);
- Reliability Engineering & System Safety (2);

程序委员会成员 Program Committee Member

- AAAI Conference on Artificial Intelligence (AAAI) 2025(1), 2026(3);
- Association for Computational Linguistics Rolling Review (ACL ARR) Feb(2), May(4) 2025;
- International Joint Conference on Artificial Intelligence (IJCAI) 2025(3);
- International Conference on Computational Linguistics (COLING) 2025(6);
- International Joint Conference on Neural Networks (IJCNN) 2025(3);
- IEEE International Symposium on Biomedical Imaging (ISBI) 2025(1);
- Conference on Health, Inference, and Learning (CHIL) 2025(2);
- Workshop on LLM Security (LLMSEC, with ACL) 2025(1);
- Workshop on Privacy-Preserving Artificial Intelligence (PPAI, with AAAI) 2025(3);
- Workshop of Deployable AI (DAI, with AAAI) 2025(3);
- Multi-Agent AI in the Real World (MARW, with AAAI) 2025(2);
- Workshop on Preventing and Detecting LLM Misinformation (PDLM, with AAAI) 2025(3);
- International Workshop on AI Governance (AIGOV, with AAAI) 2025(1);
- Workshop on Foundation Models in the Wild (FM-Wild, with ICLR) 2025(2);
- Workshop on Deep Generative Model in Machine Learning (DeLTa, with ICLR) 2025(2);
- From Understanding Model Behavior to Discovering New Scientific Knowledge (XAI4Science, with ICLR) 2025(1);
- Workshop on GenAI Watermarking (WMARK, with ICLR) 2025(1);
- Workshop on AI for Children: Healthcare, Psychology, Education (AI4CHL, with ICLR) 2025(2);

会员身份

- MLCommon/人工智能风险与可靠性(AIRR)工作组 成员/独立贡献者
- 美国电气电子工程师学会 (IEEE) 研究生会员
- 美国计算机学会 (ACM) 研究生会员
- 国际人工智能协会 (AAAI) 研究生会员
- 中国计算机学会 (CCF) 研究生会员

领导力

- Special Interest Group in Modern Interdisciplinary Research (SIGMIR) ⇒ sigmir.org 创始人&研究主管

  2025年1月，我创立了SIGMIR，一个由全球研究生组成的研究团队。SIGMIR不仅发表学术论文，还致力于工业应用，持续为学术界和工业界提供高质量的研究成果和技术创新。（Section501(c)(3)非营利组织）

媒体报道

- AI Safety in China #17 [Article] Substack
- AI Action Summit: Public Interest AI [PDF] Concordia AI
- AI Action Summit: AI of Trust - Security & Safety [PDF] Concordia AI
- 学生说｜“迁移学习”：从CS到更安全可靠的医学AI [Article] Duke Kunshan Medical Physics