李天昊

tianhao.li | tianhao.li2@duke.edu | 领英 | 谷歌学术 | Orcid | Github

教育学位

杜克大学 — 2024年8月 - 2026年5月 (预计)

理学硕士研究生 - 医学物理

研究方向: 可信人工智能；大语言模型；医学图像处理。（首年base昆山杜克）

导师: Fang-Fang Yin教授，Zhenyu Yang教授

北方工业大学 — 2020年9月 - 2024年6月

工学学士 - 信息安全 — 绩点: *3.89/4* 成绩: *90.88/100* 成绩单

核心课程: 应用密码学, 数据安全, 数字图像处理, 计算机组成原理, 操作系统, 逆向工程, 数字取证, 软件安全, 网络攻防

荣誉奖项: 优秀毕业论文 (排名1/101, Top 0.99%), 一等优秀学生奖学金 (排名1/329, Top 0.30%)

学术界研究经历

威斯康星大学麦迪逊分校 — 2024年10月 – 至今

研究实习 @ 安全基础模型系统实验室（*SaFoLab*） — 美国，威斯康星

- **职责**: 带领科研团队推进AgentFuzzer项目，提出统一的智能体模式描述符AgentSchemaDescriptor，基于此提出首个针对大模型智能体的系统性模糊测试框架，解决了对于智能体安全对齐测试泛化性难以提升的挑战。(将投稿至ICML'25)
- **导师**: Chaowei Xiao教授

浙江大学 — 2024年8月 – 2024年10月

访问研究员 @ 知识引擎实验室 — 中国，浙江

- **职责**: 带领15人科研团队推进SciSafeEval项目，提出首个面向大模型科学任务安全性的基准评测，在该基准评测下的实验结果指出：包括GPT-4o/o1-preview、LLaMa3.2、QWen2.5等在内的SOTA大语言模型(LLMs)存在生物、化学、医学、物理等科学领域的技术滥用安全风险，同时给出了基于思维链(CoT)技术与小样本学习(Few-shot)技术的有效风险缓解措施。
- **产出**: arXiv:2410.03769 (ICLR'25 Sub) | Huggingface:Tianhao0x01/SciSafeEval | Github:DavidLee528/SciSafeEval
- **导师**: 张强教授，陈华钧教授

高精尖创新研究院 — 2022年7月 – 2023年7月

研究助理 @ 虚拟与增强现实技术创新中心 — 中国，北京

- **职责**: 带领了一个8人研发团队，开发了基于步态的情报、监视和侦察（ISR）系统。实现了步态识别SaaS原型系统，并提出了包括身份认证、跟踪和近源渗透预警在内的安全特性。负责技术架构设计、技术报告撰写以及研究论文的撰写工作。
- **产出**: 成功申请10万人民币研发经费，发表7篇SCI/EI论文，赢得4项国家级专业比赛，3次口头报告与1篇海报汇报。
- **导师**: 王立军院士

工业界研究经历

天融信 — 2024年3月 – 2024年9月

安全研究员 @ 创新技术研究部 — 中国，北京

- **职责**: **(i)** 支撑机器学习模型安全评估项目原型系统落地，涉及到对于对抗攻击、投毒攻击、等算法的调试以及原型系统后端评估模块的开发; **(ii)** 支撑网络钓鱼电子邮件检测项目，监督数据集的收集和改进工作。成功应用大型语言模型 (LLM) 和监督微调 (SFT) 开发出强大的检测系统。
- **领导**: 创新研究总经理王玮博士

绿盟科技 — 2023年9月 – 2024年3月

安全研究员 @ 创新研究院天枢实验室 — 中国，北京

- **职责**: **(i)** 设计绿盟大模型安全评估系统(NSFOCUS LSAS)核心算法与原型系统; **(ii)** 通过进攻性测试，即"红队"测试，提高绿盟风云卫大模型(NSFGPT)和其他私有LLM的安全和隐私性能; **(iii)** 进行文献综述，包括可信人工智能的研究论文和Gartner咨询报告，丰富威胁情报数据库; **(iv)** 撰写LLM安全技术白皮书。
- **影响**: 发布了绿盟大模型安全评估系统(LSAS)，绿盟风云卫大模型NSFGPT以及安全行业大模型SecLLM技术白皮书
- **领导**: 主管安全研究员王星凯博士, 首席创新官&创新研究总经理刘文懋博士

部分文章发表

- Li, T., Lu, J., Chu, C., Zeng, T., Zheng, Y., Li, M., Huang, H., Wu, B., Liu, Z., Ma, K., Yuan, X., Wang, X., Ding, K., Chen, H., & Zhang, Q.*. SciSafeEval: A Comprehensive Benchmark for Safety Alignment of Large Language Models in Scientific Tasks. *The AAAI-25 Workshop on Artificial Intelligence for Cyber Security* ***(Oral)*** *(ACL ARR Dec. Subm.)* [PDF]
- Li, T., Ma, W., Zheng, Y., Fan, X., Yang, G., Li, Y., Wang, L., & Li, Z.*. A Survey on Gait Recognition Against Occlusion: Taxonomy, Dataset and Methodology. *PeerJ Computer Science, 2024 (SCI, JCR-Q1, Accepted)* [Poster]
- Ma, W., Li, Y.*, Li, T., Yang, H., Li, Z., Wang, L., & Xuan, J.. SFSWTS: EEG Emotion Recognition Based on Spatial-frequency Shifted Windows Time Self-attention Neural Network. *Neurocomputing, 2024 (SCI, JCR-Q1, Peer Review)*
- Ma, W., Zheng, Y., Li, T., Li, Z., Li, Y., & Wang, L.*. A comprehensive review of deep learning in EEG-based emotion recognition: classifications, trends, and practical implications. *PeerJ Computer Science, 2024 (SCI, JCR-Q1)* [PDF]
- Li, T., Zheng, Y., Ma, W., Wang, G., Li, Z., & Wang, L.*. Trustworthy Metaverse: A Comprehensive Investigation into Security Risks and Privacy Issues in Artificial Intelligence-Extended Reality Systems. *SID Symposium Digest of Technical Papers, 2024 (ICDT)*
- Zheng, Y., Li, T., Ma, W., Zheng, J., Li, Z.*, & Wang, L.. Unveiling Privacy Challenges: Big Data-Driven Digital Twins in Smart City Applications. *SID Symposium Digest of Technical Papers, 2024 (ICDT)*
- Zheng, Y., Li, T., Ma, W., Li, Z., Wang, L., & Li, Y.*. Automated Pricing and Replenishment Decision for Vegetable Products Based on Hybrid Machine Learning Models. *Electronics, Communications and Networks, 2024* [PDF][Oral]
- Ma, W., Li, Z., Li, T., Zheng, Y., & Wang, L.. Application of Virtual Reality Technology in the Diagnosis and Treatment of Psychological Disorders: An Electroencephalography (EEG)-Based Approach. *SID Symposium Digest of Technical Papers, 2024 (ICDT)* [Oral]
- Li, T., Zheng, Y., Zhang, H., Ma, W., & Li, Y.*. Research on Real-time Early Warning Mechanism of Aviation Safety Based on Finite State Machine Underlying in QAR Stream Data. *Proceedings of the 2023 7th International Conference on Big Data and Internet of Things, 2023 (BDIoT)* [PDF][Oral][Slide]

部分荣誉奖项

- (2024年08月) 第十七届全国大学生信息安全竞赛作品赛二等奖 [证书] 国家级
- (2024年07月) 星河生成式人工智能安全大赛攻击赛道第5名（共89队） 国家级
- (2024年02月) 2024美国大学生数学建模竞赛(MCM)S奖 [论文] 国家级
- (2023年11月) 第十一届全国大学生数字媒体科技作品及创意竞赛二等奖 [证书] 国家级
- (2023年11月) 第八届全国密码技术竞赛三等奖 [证书][名单][新闻] 国家级
- (2023年09月) 全国大学生数学建模竞赛北京赛区甲组二等奖 [证书] 省部级
- (2023年09月) 优秀学生、学习、创新实践、体育、思想品德奖学金 学校级
- (2023年08月) 第十六届全国大学生信息安全竞赛作品赛三等奖 [证书][报告][幻灯片][演示][新闻] 国家级
- (2023年06月) 第十六届全国大学生信息安全竞赛实践赛(AWDP)三等奖 [证书] 区域级
- (2023年04月) 第十三届MathorCup数学建模挑战赛一等奖 [证书][论文] 国家级
- (2023年04月) 第十四届蓝桥杯全国软件和信息技术专业人才大赛一等奖 [证书] 省部级
- (2023年02月) 2023美国大学生数学建模竞赛成功参与奖 [证书][论文] 国家级
- (2022年09月) 优秀学生、学习、创新实践、体育、思想品德奖学金 学校级
- (2022年06月) 第十六届全国大学生信息安全竞赛作品赛优胜奖 [证书][报告][幻灯片] 国家级
- (2022年06月) 第十五届全国大学生信息安全竞赛实践赛(CTF)三等奖 [证书] 区域级
- (2021年09月) 学习、创新实践奖学金 学校级
- (2021年06月) 第十二届蓝桥杯全国软件和信息技术专业人才大赛三等奖 [证书] 国家级
- (2021年04月) 第十二届蓝桥杯全国软件和信息技术专业人才大赛一等奖 [证书] 省部级

开源活动

- NVIDIA/garak (生成式人工智能红队工具，大模型安全领域的Metasploit，**3.0K+ Stars**)

  (i) 鲁棒性提升: Python解释器版本错误修复#296; Replicate大模型生成器异常修复#401; Detector检测器基类增加异常处理逻辑的增加#566;
  (ii) 新特性引入: 针对LLaVA的多模态越狱攻击#587 (使其成为**世界上首个**具备多模态红队能力的工具); 多模态红队提示词探针架构升级 (#658); 全新探针SciSafeEval的引入 (#948); 生成器网络代理特性 (garak:proxy_dev). (v0.9.0.9, v0.9.0.11, v0.9.0.13)

学术服务

- AAAI Conference on Artificial Intelligence 2025 AI Alignment Track (AAAI-AIA 2025) 程序委员会成员
- International Joint Conference on Artificial Intelligence (IJCAI 2025) 程序委员会成员
- Reliability Engineering & System Safety, Elsevier *(JCR-Q1, 中科院一区, IF=9.4, Top)* 审稿人
- ACM Transactions on Intelligent Systems and Technology *(JCR-Q1, IF=7.2)* 审稿人
- The 31st International Conference on Computational Linguistics (COLING 2025) 审稿人
- The 6th AAAI Workshop on Privacy-Preserving Artificial Intelligence (PPAI 2025) 审稿人
- 2025 International Joint Conference on Neural Networks (IJCNN 2025) 审稿人
- The 3rd Deployable AI Workshop colocated at AAAI-2025 (DAI 2025) 审稿人
- Multi-Agent AI in the Real-World Workshop at AAAI-2025 (MARW 2025) 审稿人
- AAAI 2025 Workshop on Preventing and Detecting LLM Misinformation (PDLM) 审稿人
- The First Workshop on Out-of-Label Hazards in Autonomous Driving at WACV-2025 审稿人
- 2025 IEEE International Symposium on Biomedical Imaging (ISBI 2025) 审稿人
- 3rd International Conference on Communication, Security, and Artificial Intelligence (ICCSAI 2025) 审稿人
- MLCommon/人工智能风险与可靠性(AIRR)工作组 成员/独立贡献者
- 美国电气电子工程师学会 (IEEE) 研究生会员
- 美国计算机学会 (ACM) 研究生会员
- 中国计算机学会 (CCF) 研究生会员
- Special Interest Group in Modern Interdisciplinary Research (SIGMIR) 创始人